Projet 1 — Estimer le prix d'un appartement à Paris

Machine Learning · Régression linéaire · projet individuel · à rendre le vendredi 30 octobre 2026

Ce projet est une mise en situation : l'agence et sa demande sont fictives. Les données, elles, sont réelles.

Partie 1 — Le dossier client

La demande de l'agence

Clés de Lutèce, agence immobilière parisienne (agence fictive)
Direction · Note à l'attention de l'équipe data

Objet : une première estimation de prix sur notre site

Chaque semaine, des dizaines de propriétaires nous contactent avec la même question : « Combien vaut mon appartement ? ». Pour leur répondre, un agent doit se déplacer, et beaucoup de ces demandes n'aboutissent jamais à une vente.

Nous voulons ajouter à notre site un **outil d'estimation en ligne** : le propriétaire saisit quelques informations sur son appartement (surface, nombre de pièces, arrondissement…) et obtient aussitôt une première estimation de son prix. Les propriétaires sérieux nous contacteront ensuite pour une estimation complète, avec visite.

Avant de mettre quoi que ce soit en ligne, nous avons besoin de votre **avis honnête** : de combien l'outil se trompe-t-il en moyenne ? Fait-il mieux qu'une règle simple, comme nos agents en utilisent ? Pour quels appartements peut-on lui faire confiance, et pour lesquels non ? Une estimation trop haute déçoit le client ; trop basse, elle le fait fuir chez un concurrent. Nous préférons ne rien afficher plutôt qu'afficher un chiffre faux.

© 2026 Mohamed-Réda Derraz. Support de cours ECE Paris.

Deux propriétaires en attente

Deux propriétaires ont rempli le formulaire cette semaine. Avant de les rappeler, nous voudrions l'estimation de votre outil.

	Appartement A	Appartement B
Arrondissement	11e	7e
Surface	45 m²	80 m²
Pièces principales	2	non renseigné
Dépendances (cave, parking)	1	0

Les données transmises

Les **ventes d'appartements à Paris en 2025** : **29 503 ventes réelles**, publiées par la DGFiP (« Demandes de valeurs foncières », Licence Ouverte 2.0). Les adresses ont été retirées. Personne n'a nettoyé ce fichier : il a les défauts des vraies données. Ces données ne doivent pas être republiées sur un site public.

Fichier : `ventes_appartements_paris_2025.zip`. Sur Colab, pandas le lit directement, sans le décompresser.

Colonne	Ce qu'elle contient
`id_vente`	Numéro de la vente (ne sert pas à prédire)
`mois`	Mois de la vente en 2025
`arrondissement`	Arrondissement de Paris (1 à 20)
`surface_m2`	Surface habitable (m²)
`surface_carrez_m2`	Surface « loi Carrez »
`nb_pieces`	Nombre de pièces principales
`nb_lots`	Nombre de lots vendus ensemble
`nb_dependances`	Caves et parkings vendus avec l'appartement
`prix_eur`	**Ce qu'on veut estimer** : le prix de vente, en euros

Ce que vous livrez à l'agence

1. **L'étude, dans un notebook** : du fichier brut au modèle livré. Chaque étape a un titre, son code, et une ou deux phrases qui disent ce que vous avez constaté et ce que vous avez décidé. Notre prestataire web doit pouvoir la relire et la réexécuter.
2. **Le modèle enregistré dans un fichier**, rechargé à la fin du notebook pour estimer les appartements A et B.

© 2026 Mohamed-Réda Derraz. Support de cours ECE Paris.

3. **Une note de conclusion pour la direction**, en fin de notebook, sans jargon : la question, les données gardées et écartées, l'erreur moyenne en euros comparée à une règle simple, votre recommandation (peut-on mettre l'outil en ligne ? sous quelle forme ?) et ses limites.

Partie 2 — Le cadre du projet

La démarche

C'est celle du cours : les dix étapes de la présentation, que le TP sur les voitures d'occasion vous a fait parcourir une fois. Le notebook est vide, c'est à vous de l'organiser. Ce que chaque étape doit contenir ici :

1. **Inspecter** : notez au moins trois problèmes (valeurs manquantes, extrêmes, incohérences).
2. **Doublons** : y en a-t-il ? Que décidez-vous, et pourquoi ?
3. **Périmètre** : chaque règle justifiée en une phrase. Demandez-vous si chaque vente est bien celle d'un appartement ordinaire.
4. **Explorer** : deux ou trois graphiques, chacun suivi de ce qu'il montre.
5. **Séparer** : 20 % des données mis de côté avant tout calcul appris.
6. **Référence** : une règle simple, sans modèle, et son erreur. Votre modèle devra faire mieux.
7. **Pipeline** : valeurs manquantes, encodage des catégories, normalisation et régression linéaire, réunis dans un pipeline scikit-learn. Demandez-vous quelles colonnes sont des nombres, et lesquelles sont des catégories écrites avec des chiffres.
8. **Versions** : au moins quatre, en ne changeant qu'une chose à la fois, comparées par validation croisée dans un tableau. Laquelle retenez-vous, et l'écart avec les autres est-il réel ? Le test, lui, sert à mesurer la version retenue.
9. **Interpréter** : au moins trois coefficients ou effets traduits en phrases, et les plus grosses erreurs examinées. Qu'est-ce que le modèle ne sait pas ?
10. **Livrer** : le meilleur pipeline enregistré, rechargé, et les estimations des appartements A et B. Puis la note de conclusion.

Les règles

- **Régression linéaire uniquement** : c'est le modèle de ce projet.
- **Sur Colab**, un seul notebook, qui **s'exécute de bout en bout** (Exécution › Tout exécuter) sans erreur.
- Travail **individuel**. Vous pouvez vous aider de tout ce qui a été fait en cours ; chaque ligne que vous rendez, vous devez savoir l'expliquer.
- Vous pouvez commencer en classe dès le TP terminé. Vos questions sont les bienvenues au cours du 23 octobre.

© 2026 Mohamed-Réda Derraz. Support de cours ECE Paris.

Ce que vous rendez

Le notebook complété, exécuté, avec ses résultats visibles (Fichier › Télécharger › .ipynb), **avant le vendredi 30 octobre 2026 à 23 h 59**. Le lieu de dépôt est indiqué en cours.

Comment le projet est validé

Le projet est validé ou non. **Le score du modèle ne décide pas** : un projet dont le modèle bat de peu la référence, mais qui le constate, l'explique et en tire une recommandation honnête, est validé.

Critère	Validé quand…
Les données	Doublons, valeurs aberrantes et manquantes repérés ; chaque traitement justifié en une phrase
L'exploration	Deux ou trois graphiques utiles à la question, chacun commenté
L'évaluation	Une référence ; le découpage fait avant tout calcul appris ; les erreurs dites en euros
Les versions	Au moins quatre versions comparées dans un tableau, et le choix final expliqué
L'analyse	Les coefficients ou effets traduits en phrases ; les limites du modèle dites
La rédaction	Une conclusion lisible par l'agence ; un notebook qui s'exécute de bout en bout

© 2026 Mohamed-Réda Derraz. Support de cours ECE Paris.